

TEMARL — আমরা কী করেছি, কী পেয়েছি, এবং এর অর্থ কী

Transformer-Enhanced Multi-Agent Reinforcement Learning for Adaptive Honeypot Deception। এই প্রতিবেদনে প্রতিটি সিদ্ধান্ত, প্রতিটি পরীক্ষা, প্রতিটি ফলাফলের টেবিল ব্যাখ্যা করা হয়েছে — এবং সংভাবে বলা হয়েছে কেন থিসিসের শিরোনামের দাবিটি প্রমাণিত হয়নি, এবং এর বদলে থিসিস কী দাবি করতে পারে।

এক অনুচ্ছেদে পুরো সারসংক্ষেপ

আমরা একটি হানিপট প্রতারণা ব্যবস্থা তৈরি করেছি, যেখানে চারজন রক্ষী এজেন্ট আক্রমণকারীর বিরুদ্ধে নকল টোপ (decoy) বসায়। আক্রমণকারীর আচরণ আসে প্রকৃত আক্রমণের তথ্য থেকে। **ব্যবস্থাটি কাজ করে:** এটি ৬০.৪% ক্ষেত্রে আক্রমণকারীকে আটকাতে পারে, যেখানে আক্রমণকারীর কোনো মডেল ছাড়া রক্ষী পারে ৫৪.৮%, আর কোনো প্রতারণা ছাড়া মাত্র ৩৬.৪%। কিন্তু শিরোনামের নির্দিষ্ট দাবিটি — যে **ট্রান্সফরমার** পুরোনো মডেলগুলোর চেয়ে ভালো — **এখানে সত্য নয়**। বরং আমরা আরও নির্ভুল এবং ইতিবাচক একটি বিষয় প্রমাণ করেছি: ট্রান্সফরমার GRU-এর **পরিসংখ্যানগতভাবে সমান** ফলাফল দেয়, কিন্তু ব্যবহার করে মাত্র **৪৪% প্যারামিটার**।

0.6040

ব্যবস্থার সাফল্যের হার

+0.057

মডেলবিহীন রক্ষীর চেয়ে বেশি
($p=0.0004$)

44.4%

GRU-এর তুলনায়
ট্রান্সফরমারের প্যারামিটার

$p=0.0001$

সমতা প্রমাণিত, মূল মানচিত্রে

১. থিসিস কী প্রমাণ করতে চেয়েছিল

হানিপট হলো একটি নকল কম্পিউটার, যা আক্রমণকারীকে ফাঁদে ফেলতে ব্যবহৃত হয়। রক্ষী যদি **আন্দাজ করতে পারে আক্রমণকারী পরের ধাপে কী করবে**, তাহলে সে সঠিক জায়গায় সঠিক ধরনের নকল টোপ রাখতে পারে। থিসিসের প্রস্তাব ছিল — **ট্রান্সফরমার** (ChatGPT-এর পেছনের মডেল) পুরোনো মডেল যেমন **GRU** বা **LSTM**-এর চেয়ে ভালো আন্দাজ করবে, কারণ আক্রমণ হলো ধাপে ধাপে ঘটা একটি ক্রম (sequence)।

এই একটি বাক্যের ভেতরে দুটি আলাদা দাবি আছে

দাবি	কী প্রমাণ লাগে	অবস্থা
ক — ব্যবস্থার দাবি। এই ব্যবস্থাটি তৈরি করা (ট্রান্সফরমার + মাল্টি-এজেন্ট RL + MITRE-ভিত্তিক প্রতারণা) কাজ করে।	দেখাতে হবে এটি এমন রক্ষীদের হারায় যাদের আক্রমণকারীর মডেল নেই।	প্রমাণিত
খ — স্থাপত্যের দাবি। ট্রান্সফরমার এই কাজে GRU/LSTM-কে হারায়।	ন্যায্য মুখোমুখি তুলনা ও পরিসংখ্যান।	প্রমাণিত হয়নি

এই প্রতিবেদনের বেশিরভাগ অংশ **খ** দাবিটি যতটা সম্ভব কঠোর ও ন্যায্যভাবে পরীক্ষা করার বিবরণ, এবং কেন সং উত্তর হলো "না"। অন্যদিকে **ক** দাবিটি টিকে আছে — থিসিস এর ওপরেই দাঁড় করানো উচিত।

২. ডেটাসেট — এটি কী এবং আমরা এর সাথে কী কী করেছি

২.১ কোন ডেটাসেট এবং কেন

CAM-LDS হলো একটি প্রকাশিত ডেটাসেট, যেখানে একটি পরীক্ষামূলক নেটওয়ার্কে ("AttackBed" টেস্টবেড) প্রকৃত, স্ক্রিপ্ট করা আক্রমণ অভিযান চালানো হয়েছে। প্রতিটি অভিযান হলো MITRE ATT&CK কৌশলের একটি ক্রম — আক্রমণকারীরা বাস্তবে কী করে তার আদর্শ তালিকা (যেমন T1059 = ক্ষতিকর কমান্ড চালানো)।

আমরা **COMISET** নামের আরও বড় একটি হানিপট লগ ডেটাসেটও দেখেছি, কিন্তু সেটি শুধু এনকোডার প্রি-ট্রেনিং পরীক্ষার জন্য ব্যবহার করেছি — মূল ফলাফলে নয়।

বৈশিষ্ট্য	মান	সহজ ভাষায় অর্থ
প্লেবুক (রান)	36	৩৬টি রেকর্ড করা আক্রমণ
চিহ্নিত কৌশল ধাপ	1,347	১,৩৪৭টি আলাদা আক্রমণ-পদক্ষেপ
আলাদা অভিযান (scenario)	7	৭টি ভিন্ন আক্রমণ-কাহিনি
মূল কৌশল (technique)	82	৮২ ধরনের আক্রমণ-পদক্ষেপ
কৌশলগত লক্ষ্য (tactic)	13	১৩টি আক্রমণ-লক্ষ্য
Kish কার্যকর নমুনা সংখ্যা	3.09	৩৬টি রান আসলে মাত্র ~৩টি স্বাধীন অভিযানের সমান। এটি খুবই ছোট ডেটাসেট।

২.২ আমরা ডেটাসেট নতুন করে তৈরি করেছি এবং পাঁচটি প্রকৃত ক্রটি পেয়েছি

আগের সংস্করণটি গবেষণাপত্রের লেখা দেখে হাতে তৈরি করা হয়েছিল। আমরা সেটি বাদ দিয়ে সরাসরি ৩৬টি প্রকাশিত প্লেবুক ফাইল পার্স করেছি। এরপর প্রথমটিকে যাচাই করার জন্য সম্পূর্ণ আলাদাভাবে লেখা দ্বিতীয় একটি পার্সার ব্যবহার করেছি। সেটি প্রথমটির ক্রটি ধরে ফেলে।

ধাপ	ক্রটি	ক্ষতি
১	দুটি ফাইলে <code>tactics:</code> -এর বদলে একবচন <code>tactic:</code>	একটি সম্পূর্ণ অভিযান নীরবে বাদ পড়ে যাচ্ছিল
১	<code>.j2</code> ও <code>.j2.yml</code> আসলে একই প্লেবুক	একটি অভিযান দুইবার গণনা হচ্ছিল
২	ব্লক-ক্রম ক্রটি — <code>tactics:</code> যদি <code>techniques:</code> -এর আগে থাকে, কিছুই রেকর্ড হতো না	T1190, T1059.004, T1095 হারিয়ে যাচ্ছিল
২	লাইনের ভেতরে <code>#</code> মন্তব্যের ক্রটি (২ ধরনের)	১টি T1222.002 ও ৪টি T1219 হারিয়ে যাচ্ছিল
২য় ধাপের মোট ফল		৮টি হারানো পদক্ষেপ উদ্ধার: ১,৩৩৯ → ১,৩৪৭

এছাড়া উৎস-যাচাইয়ে দেখা গেল, হাতে তৈরি সংস্করণে ৬টি কৌশল সম্পূর্ণ বাদ পড়েছিল (T1069, T1218, T1518, T1572, T1614, T1615) — অর্থাৎ সব আক্রমণ-পদক্ষেপের ৬.২০% নীরবে "অজানা" হিসেবে ফেলে দেওয়া

হচ্ছিল। আমরা শব্দভাণ্ডার ৭৮ থেকে ৮৪ কৌশলে বাড়িয়েছি, তবে শুধু যোগ করে — যাতে পুরোনো আইডি বৈধ থাকে।

নিজেদের ডেটা সম্পর্কে তিনটি দাবি আমাদের প্রত্যাহার করতে হয়েছে

- "৮২টি কৌশল ও ১৩টি ট্যাকটিক প্রকাশিত গবেষণাপত্রের সাথে হুবহু মেলে।" ভুল। এই আপাত-নিখুঁত মিলটি আসলে ত্রুটিগুলো একে অপরকে কাটাকাটি করার দুর্ঘটনা ছিল। প্রকৃতপক্ষে ৮২, আর গবেষণাপত্রে ৮১।
- "হাতে তৈরি সংস্করণ T1095 কৌশলটি বানিয়ে ফেলেছিল।" ভুল। T1095 সত্যিই আছে — `scenario_7.j2` ফাইলের ৯৫ নম্বর লাইনে। ব্লক-ক্রম ত্রুটি এটিকে আড়াল করছিল। ওই সংস্করণের নির্ভুলতা ১০০%, ৯৮.৭% নয়।
- "COMISET, CAM-LDS-এর চেয়ে ১১৫৬ গুণ বড়।" বিভ্রান্তিকর। এর ৯৮.৫% ধাপই একই কাজের পুনরাবৃত্তি। পুনরাবৃত্তি বাদ দিলে থাকে ২৩,৭৫৪টি ব্যবহারযোগ্য পরিবর্তন — প্রকৃত সুবিধা প্রায় ১৮ গুণ, ১১৫৬ নয়।

২.৩ হ্যাঁ — আমরা ডেটা ক্লাস্টার করেছি, এবং সেই ক্লাস্টারিংই ব্যর্থতার কারণ

আপনি বিশেষভাবে ক্লাস্টারিং নিয়ে জানতে চেয়েছেন। আমরা এক জায়গায় ক্লাস্টার করেছিলাম, এবং সেটিই প্রকল্পের সবচেয়ে ক্ষতিকর সিদ্ধান্ত হয়ে দাঁড়ায়।

`consolidate_intent_classes()` নামের একটি ফাংশন ৭টি অভিযানকে ৩টি "উদ্দেশ্য শ্রেণিতে" (intent class) ভাগ করেছিল। ভাগ করার নিয়ম ছিল: যেসব অভিযানের জন্য একই টোপ সবচেয়ে ভালো, সেগুলো একই উদ্দেশ্য। এমনকি ক্লাস্টার তিনটির নামই রাখা হয়েছিল তাদের উত্তর অনুযায়ী: `decoy_persona`, `decoy_file`, `decoy_credential`।

কেন এটি থিসিসের প্রশ্নের জন্য মারাত্মক

আপনি যদি আক্রমণগুলোকে "কোন উত্তরটি সঠিক" দিয়ে ভাগ করেন, তাহলে গ্রুপ জানা মানেই উত্তর জানা। রক্ষীকে আর ক্রম পড়তেই হয় না — শুধু বুঝতে হয় সে ৩টি বাক্সের কোনটিতে আছে।

আমরা মেপে দেখেছি এটি কতটা খারাপ। প্রতিটি ক্লাস্টারের ভেতরে সেরা টোপ ছিল দুটি ক্লাস্টারে ৮৪টির মধ্যে ৮৪টি কৌশলের জন্যই একই, আর তৃতীয়টিতে ৮৪-এর মধ্যে ৮৩টির জন্য। ফলে:

রক্ষী কী জানে	প্রত্যাশিত ফল	লাভ
কিছুই না (একটিমাত্র সেরা স্থির টোপ)	0.3584	—
ক্লাস্টারের নাম (৩টির মধ্যে বাছাই)	0.7426	+0.3842
পরের কৌশলের নিখুঁত পূর্বাভাস	0.7427	+0.0001

নিখুঁত ক্রম-পূর্বাভাসের মূল্য মাত্র +0.0001 — অর্থাৎ ক্লাস্টার-নামের মূল্যের ০.০%। কাজটি আসলে ক্রমের ছদ্মবেশে ৩-শ্রেণির শ্রেণিবিন্যাস ছিল। কোনো ট্রান্সফরমার, GRU বা LSTM এখানে নিজেকে আলাদা প্রমাণ করতে পারত না।

২.৪ যে হিসাব-ক্রটি ক্রমের ৮৭% গঠন নষ্ট করেছিল

পরিবেশটি প্রতিটি অভিযানকে একটি **রূপান্তর সারণিতে** (transition table) পরিণত করে: "A কৌশলের পরে B কৌশলের সম্ভাবনা কত?" এই সারণি তৈরির কোডে একটি ক্ষতিকর লাইন ছিল:

`T[:, j] += 1.2` — যা **প্রতিটি সারিতে** একইভাবে যোগ হতো।

প্রতিটি সারিতে একইভাবে যোগ হওয়া সংখ্যা কীসের পরে কী আসে সে সম্পর্কে **শূন্য তথ্য** বহন করে — সংজ্ঞা অনুসারেই। আরও খারাপ, এটি প্রতি সারিতে ৭.২-৮.৪ একক যোগ করত, যেখানে প্রকৃত পর্যবেক্ষিত ডেটা থেকে আসত মাত্র ৪.০ একক — অর্থাৎ গোলমাল সংকেতকে প্রায় ২:১ অনুপাতে ছাপিয়ে যেত। ৫৫% থেকে ৭৪% সারি একে অপরের হুবহু সমান হয়ে গিয়েছিল।

পরিমাপ	আগে	লাইনটি সরানোর পরে
অভিযানপ্রতি রক্ষিত ক্রম-তথ্য	0.627 bits	1.935 bits
(প্রকৃত ডেটায় আছে)		4.83 bits — ৮৫.৪% পূর্বানুমেয়
নিখুঁত ক্রম-পূর্বাভাসের মূল্য (payoff)	+0.0002	+0.1776
নিখুঁত ক্রম-পূর্বাভাসের মূল্য (সাফল্যের হার)	+0.0005	+0.0800
অভিযানপ্রতি ভিন্ন সেরা টোপের সংখ্যা	1.33	4.33

প্রমাণ যে এটি এক-লাইনের পরিবর্তন, ফলাফল সাজানো নয়। ধ্রুবকটি আবার ১.২ করলে পুরোনো অভিযান-প্রোফাইল **হুবহু বিট-পর্যায়**ে ফিরে আসে (সর্বোচ্চ পার্থক্য ০.০০০০০০)। আমরা আরও দুটি সংস্কার পরীক্ষা করেছিলাম যেগুলো সাহায্য করবে বলে আশা করেছিলাম — উন্নত স্মুদিং, এবং ৩টির বদলে ৭টি অভিযান ব্যবহার — কিন্তু **দুটোই বাতিল করেছি**, কারণ পরিমাপে দেখা গেছে সেগুলো পরিস্থিতি আরও খারাপ করে (−০.০৫৪৪ ও −০.০৩০৫)। শুধু গণিত দিয়ে যেটি যুক্তিসঙ্গত, সেটিই রাখা হয়েছে।

৩. পরিবেশ — তিনটি, এবং প্রতিটি কেন

"পরিবেশ" হলো সেই সিমুলেটেড নেটওয়ার্ক যেখানে আক্রমণকারী ও চারজন রক্ষী এজেন্ট পরস্পরের সাথে কাজ করে। আমরা তিনটি তৈরি করেছি, প্রতিটি আগেরটির পাশে রেখে — যাতে ফলাফল তুলনাযোগ্য থাকে।

পরিবেশ	এটি কী	কেন তৈরি করেছি
১. <code>env_v2.py</code> হিমায়িত নিয়ন্ত্রণ	স্থির ৫-জোন নেটওয়ার্ক। ৪ জন রক্ষী এজেন্ট, প্রতি জোনে একজন। আক্রমণকারী জোনের মধ্যে চলাফেরা করে ও ATT&CK কৌশল প্রয়োগ করে। পুরস্কার = $0.70 \times$ আটকানো + $0.90 \times$ টোপ-মিলের মান।	বৈজ্ঞানিক নিয়ন্ত্রণ। কখনো পরিবর্তন করা হয়নি। বাকি সবকিছুকে এটি হুবহু পুনরুৎপাদন করতে হবে।
২. <code>env_entity.py</code> পরিবর্তনশীল কাঠামো	একই নিয়ম, কিন্তু নেটওয়ার্কে যেকোনো সংখ্যক জোন ও হোস্ট থাকতে পারে। রক্ষী স্থির ভেক্টরের বদলে <i>মেশিনের তালিকা</i> দেখে। কাজ হয়ে যায় জোড়া: (<i>কোন টোপ, কোন মেশিনে</i>)।	নেটওয়ার্কের আকার বদলালে অ্যাটেনশন সাহায্য করে কি না তা পরীক্ষা করতে — Symes Thompson et al. (arXiv:2410.17647) অনুসরণে। যাচাই করা হয়েছে এটি <code>env_v2</code> হুবহু পুনরুৎপাদন করে: ১,১২৬ ধাপে ০টি অমিল ।
৩. <code>profiles_v5.py</code> + ক্যালিব্রেশন সংস্কারকৃত পরিবেশ	একই পরিবেশ, তবে আক্রমণকারীর মডেল ক্ষতিকর ধ্রুবক ছাড়া নতুন করে তৈরি, এবং ধরা-পড়ার নিয়ম পুনঃসমন্বিত যাতে পরিমাপ কার্যকর থাকে।	কারণ আমরা আবিষ্কার করেছি ১ ও ২ নম্বর পরিবেশ থিসিসের প্রশ্নের উত্তরই দিতে পারত না (দেখুন ২.৩–২.৪)।

৩.১ চারটি পরীক্ষার শর্ত ("regime")

Regime	এটি কী	কী পরীক্ষা করে
A	মূল ৫-জোন মানচিত্র	মৌলিক দক্ষতা
B	নতুন মানচিত্র, প্রশিক্ষণে দেখা আকার	সাধারণ সাধারণীকরণ
C	অদেখা কাঠামো (ভিন্ন ফায়ারওয়াল ঘনত্ব)	কাঠামোগত সাধারণীকরণ
D	অদেখা আকার (৯, ১১, ১৩ জোন)	আকারগত সাধারণীকরণ — সবচেয়ে কঠিন

৩.২ পরিবেশ সংস্কার পরিমাপ নষ্ট করে দিয়েছিল, সেটিও ঠিক করতে হয়েছে

ক্ষতিকর ধ্রুবক সরানোর ফলে পর্ব (episode) **৩ গুণ দীর্ঘ** হয় ($5.85 \rightarrow 18-22$ ধাপ)। এতে সাফল্যের হার **০.৭৯–০.৯৮-এ সম্পৃক্ত (saturate)** হয়ে যায় — সব নীতিই ভালো দেখায়, ফলে তুলনা অসম্ভব। এটি ঠিক সেই ব্যর্থতা যা ধরার জন্য প্রকল্পের নিজস্ব পরিবেশ-গেট লেখা হয়েছিল (এই প্রকল্পের ১ম সংস্করণ এ কারণেই বাতিল হয়েছিল)।

তাই আমরা দুটি ধ্রুবক **আগে থেকে নির্ধারিত চারটি শর্তের** বিপরীতে পুনঃসমন্বয় করেছি, শুধুমাত্র শেখে না এমন বেসলাইন নীতি ব্যবহার করে (যাতে কোনো স্থাপত্য পছন্দকে প্রভাবিত করতে না পারে)। পরীক্ষিত ২০টি সমন্বয়ের মধ্যে **ঠিক একটি** চারটি শর্তই পাস করে:

শর্ত (পরীক্ষার আগে ঘোষিত)	প্রয়োজন	নির্বাচিত মান
C1 — সম্পৃক্ত নয়	প্রতারণাহীন নীতি ০.২৫–০.৪০ এর মধ্যে	0.367 ✓
C2 — পার্থক্য করতে সক্ষম	সেরা – খারাপ ≥ 0.15	0.217 ✓
C3 — পড়ার মতো ইতিহাস আছে	পর্ব ≥ 10 ধাপ	18.4 ✓
C4 — ক্রমের প্রকৃত মূল্য আছে	ক্রম-মূল্য ≥ 0.03	0.050 ✓
নির্বাচিত কনফিগারেশন		<code>goal_steps=3, cap_scale=0.35</code>

৪. আমরা যেসব মডেল তৈরি করেছি এবং কতটা বদলেছি

দুই ধরনের এনকোডার জড়িত। ইতিহাস এনকোডার আক্রমণকারীর অতীত কৌশল পড়ে। নেটওয়ার্ক এনকোডার মেশিনের তালিকা পড়ে।

মডেল	ধরন	প্যারামিটার	ভূমিকা ও আমরা কী বদলেছি
Transformer-RoPE	ইতিহাস	156,310	থিসিসের মূল মডেল। আমরা দুইবার বদলেছি: (১) সাইনুসয়ডাল পজিশন এনকোডিং বদলে রোটারি (RoPE); (২) সমান সার্চ বাজেটে গভীরতা/প্রস্থ পুনঃসমন্বয়। দুটোই এটিকে সাহায্য করেছে।
Transformer-Sinusoidal	ইতিহাস	161,174	মূল সংস্করণ — আমাদের নিজেদের কনফিগারেশন এটিকে কতটা ক্ষতি করছিল তা মাপতে রাখা।
GRU	ইতিহাস	351,702	প্রধান প্রতিদ্বন্দ্বী। আমরা <code>pack_padded_sequence</code> যোগ করেছি যাতে প্যাডিং এটিকে দূষিত করতে না পারে — এটি না করলে GRU অন্যায়ভাবে দুর্বল হয় এবং ট্রান্সফরমার ভুয়া কারণে "জেতে"।
GRU-d32	ইতিহাস	236,598	আমাদের উদ্ভাবিত একটি নিয়ন্ত্রণ: ট্রান্সফরমারের মতো সরু আউটপুটসহ GRU — যাতে বোঝা যায় ট্রান্সফরমারের কোনো সুবিধা আসলে শুধু আউটপুটের আকারের কারণে কি না।
LSTM	ইতিহাস	450,518	আপনার অনুরোধে যোগ করা। মূল পাণ্ডুলিপিতে এটি "ভবিষ্যৎ কাজ" হিসেবে ছিল, কখনো তৈরি হয়নি। একই প্যাডিং নিয়ম; GRU-এর সমন্বিত সেটিংস হুবহু দেওয়া হয়েছে।
SetEncoder	ইতিহাস	~74,000	ক্রম-অন্ধ নিয়ন্ত্রণ। ট্রান্সফরমার একে না হারাতে পারলে ক্রমে কোনো ব্যবহারযোগ্য সংকেত নেই।
EntityTransformer	নেটওয়ার্ক	74,369	মেশিনের ওপর অ্যাটেনশন। DeepSets-এর সাথে ০.৭%-এর মধ্যে ক্ষমতা-মিলিত।
DeepSets	নেটওয়ার্ক	73,828	মেশিনের ওপর ক্রম-অন্ধ পুলিং।

প্রতিটি মডেলে আমরা যে ন্যায্যতার নিয়ম মেনেছি

- ক্ষমতা মিলিত (এনটিটি এনকোডারে ০.৭%-এর মধ্যে)।
- একই প্যাডিং ব্যবস্থাপনা — ট্রান্সফরমারের ভুয়া জয় তৈরির সবচেয়ে সাধারণ উপায় হলো RNN-এ প্যাডিং চুকতে দেওয়া।
- সমান টিউনিং বাজেট — প্রতিটির জন্য ১৬টি র‍্যান্ডম সার্চ ট্রায়াল।
- একই ডেটা, একই সিড, একই মূল্যায়ন — প্রতিটি তুলনা একই সিডে জোড়া।

৪.১ সবচেয়ে গুরুত্বপূর্ণ আবিষ্কার: আমরা নিজেরাই নিজেদের ট্রান্সফরমারকে দুর্বল করছিলাম

আগের এক ফলাফলে GRU আক্রমণ-পূর্বাভাসে ট্রান্সফরমারকে +0.1388 ব্যবধানে হারিয়েছিল (খুব বড় ও তাৎপর্যপূর্ণ)। তদন্ত করে দেখা গেল ওই ব্যবধান আমাদেরই দোষ — মডেলের বৈশিষ্ট্য নয়:

দুই মডেলেই সমানভাবে প্রয়োগ করা সংশোধন	ব্যবধানে প্রভাব
সাইনুসয়ডালের বদলে রোটারি পজিশন এনকোডিং	+0.026 থেকে +0.070
সমান ১৬-ট্রায়াল হাইপারপ্যারামিটার সার্চ	বাকিটা পূরণ করে
সংশোধিত ব্যবধান	+0.0000 — সমতা, ৪৪% প্যারামিটারে

৫. কীভাবে বেঞ্চমার্ক করেছি — পরিমাপের যন্ত্র

৫.১ রেফারেন্স সিঁড়ি (ladder)

"সাফল্যের হার ০.৪৫" — এই সংখ্যাটি একা কিছুই বোঝায় না। তাই আমরা একটি **রেফারেন্স নীতির সিঁড়ি** বানিয়েছি, প্রতিটি ধাপে আগেরটির চেয়ে বেশি তথ্য:

ধাপ	কী জানে
null	কিছুই না — কোনো টোপ বসায় না। সর্বনিম্ন সীমা।
random	এলোমেলোভাবে টোপ বাছে।
best_fixed	সবসময় একটিমাত্র সেরা টোপ বসায়। আক্রমণকারীর কোনো মডেল নেই — শেখা মডেলকে এটিই ছাড়িয়ে যেতে হবে।
profile	নিখুঁতভাবে জানে ৩টি ক্লাস্টারের কোনটির মুখোমুখি।
transition	পরের কৌশল নিখুঁতভাবে পূর্বাভাস দেয়। যেকোনো ইতিহাস এনকোডারের জন্য এটিই সর্বোচ্চ সীমা।
clairvoyant	প্রকৃত পরের কৌশল দেখে ফেলে। অর্জন-অসম্ভব; উপরের সবকিছুর সীমা।

মূল পরিমাপ: "ক্রম-মূল্য" (sequence value)

ক্রম-মূল্য = (নিখুঁত পরবর্তী-কৌশল মডেল) - (নিখুঁত ক্লাস্টার নাম)

এটি শূন্য হলে কোনো ক্রম-মডেলই নিজেকে আলাদা প্রমাণ করতে পারবে না, সে যত ভালোই হোক।
এই একটি সংখ্যাই প্রকাশ করেছে যে মূল পরীক্ষাটি নিজের প্রশ্নের উত্তর দিতে অক্ষম ছিল।

৫.২ বৈধতা-গেট (validity gate)

দুটি মডেল তুলনার আগে আমরা এখন যাচাই করি **প্রতিটি মডেল আসলেই কাজটি শিখেছে কি না** — তাকে `best_fixed` -কে তাৎপর্যপূর্ণভাবে হারাতে হবে। এই যাচাই ছাড়া "কোনো পার্থক্য নেই" ফলাফল অর্থহীন, কারণ তখন "দুটোই ভালো" আর "কোনোটাই শেখেনি" — এই দুটির পার্থক্য বোঝা যায় না।

৬. ফলাফল — প্রতিটি পরীক্ষা, ধারাবাহিকভাবে

৬.১ পরিমাপযন্ত্র, সংস্কারের আগে ও পরে

নীতি	A	B	C	D	A	B	C	D
	মূল পরিবেশ				সংস্কারকৃত পরিবেশ			
null (প্রতারণা নেই)	0.3150	0.3090	0.3115	0.3030	0.3680	0.3635	0.3615	0.3515
random	0.4235	0.4090	0.3990	0.3495	0.5320	0.4935	0.5030	0.4080
best_fixed	0.4540	0.4340	0.4340	0.3625	0.5920	0.5475	0.5470	0.4465
profile	0.6245	0.5820	0.5825	0.4470	0.6050	0.5590	0.5565	0.4490
transition	0.6250	0.5825	0.5830	0.4475	0.6845	0.6390	0.6370	0.5035
clairvoyant	0.6610	0.6200	0.6180	0.4800	0.7430	0.7155	0.7150	0.5730
ক্রম-মূল্য	+0.0005	+0.0005	+0.0005	+0.0005	+0.0795	+0.0800	+0.0805	+0.0545
পর্বের দৈর্ঘ্য (ধাপ)	5.5	5.6	5.6	5.8	17.3	18.1	18.2	20.2

মোট সারিটি পড়ুন। মূল পরিবেশে একটি **নিখুঁত** ক্রম-মডেলের মূল্য ছিল **+0.0005** — কিছুই না। সংস্কারের পরে তা **+0.0800**, অর্থাৎ **১৬০ গুণ বৃদ্ধি**। শুধু দ্বিতীয় কলামটিই থিসিসের ন্যায্য পরীক্ষা।

৬.২ পরীক্ষা v4 — মূল পরিবেশে (যেটির ফল ব্যাখ্যাযোগ্য নয়)

মডেল / উদ্দেশ্য	A	B	C	D	প্যারামিটার
Transformer-RoPE / action	0.4525	0.4300	0.4295	0.3655	156,310
Transformer-RoPE / next	0.4695	0.4410	0.4415	0.3680	156,310
Transformer-Sin / action	0.4585	0.4320	0.4360	0.3575	161,174
Transformer-Sin / next	0.4435	0.4220	0.4240	0.3655	161,174
GRU / action	0.4725	0.4500	0.4530	0.3805	351,702
GRU / next	0.4545	0.4345	0.4355	0.3660	351,702

কেন v4 কোনো উত্তর দিতে পারেনি — যে বৈধতা-গেট কখনো চালানো হয়নি

মডেল	best_fixed-এর তুলনায়	সম্ভাব্য উন্নতির কত অংশ	p	শিখেছে?
Transformer-RoPE / action	-0.0040	-2.7%	0.852	না
Transformer-RoPE / next	+0.0070	4.7%	0.497	না
Transformer-Sin / action	-0.0020	-1.4%	0.881	না
Transformer-Sin / next	-0.0120	-8.1%	0.446	না
GRU / action	+0.0160	10.8%	0.050	হ্যাঁ
GRU / next	+0.0005	0.3%	0.967	না

ছয়টির মধ্যে পাঁচটি মডেল "সবসময় একটিমাত্র টোপ বসানো"-কেও হারাতে পারেনি। যে দুটি মডেল কিছুই শেখেনি, তাদের তুলনা করে স্থাপত্য সম্পর্কে কিছুই জানা যায় না। এ কারণেই আমরা পরীক্ষাটি নতুন করে বানিয়েছি।

৬.৩ পরীক্ষা v5 — সংস্কারকৃত পরিবেশে (প্রকৃত পরীক্ষা)

প্রথমে বৈধতা-গেট — এবার পাঁচটি মডেলই সত্যিকারভাবে শিখেছে:

মডেল	সাফল্য (B)	best_fixed-এর তুলনায়	উন্নতির অংশ	p	গেট
Transformer-RoPE / DeepSets	0.6040	+0.0565	61.7%	0.0004	পাস
GRU / DeepSets	0.6100	+0.0625	68.3%	0.0000	পাস
GRU-d32 / DeepSets	0.6055	+0.0580	63.4%	0.0018	পাস
Transformer-RoPE / EntityTransformer	0.6075	+0.0600	65.6%	0.0001	পাস
GRU / EntityTransformer	0.6175	+0.0700	76.5%	0.0001	পাস
LSTM / DeepSets পরে যুক্ত	0.6085	+0.0610	66.7%	0.0001	পাস

সম্পূর্ণ ফলাফল, চারটি regime (১০টি জোড়া সিড, প্রতিটিতে ২০০টি পরীক্ষা-পর্ব):

মডেল	A	B	C	D	প্যারামিটার	সময় (সে.)
Transformer-RoPE / DeepSets	0.6540	0.6040	0.6025	0.4865	156,310	115
GRU / DeepSets	0.6550	0.6100	0.6080	0.4820	351,702	51
GRU-d32 / DeepSets	0.6520	0.6055	0.6050	0.4920	236,598	48
Transformer-RoPE / EntityTransformer	0.6525	0.6075	0.6070	0.4810	156,310	126
GRU / EntityTransformer	0.6565	0.6175	0.6135	0.5000	351,702	64
LSTM / DeepSets পরে যুক্ত	0.6560	0.6085	0.6115	0.4845	450,518	54

ছয়টি ভিন্ন স্থাপত্যের পার্থক্য A মানচিত্রে মাত্র **0.0045** এবং D মানচিত্রে **0.019**। বাস্তবিক অর্থে এরা একই।

৬.৪ LSTM তুলনা — অ্যাবলেশন সম্পূর্ণ করা

মূল পাণ্ডুলিপিতে LSTM তুলনা "ভবিষ্যৎ কাজ" হিসেবে ছিল, কখনো তৈরি হয়নি। ফলে "অ্যাটেনশন বনাম রিকারেন্স" সংক্রান্ত প্রতিটি বক্তব্য মাত্র **একটি** রিকারেন্ট মডেলের বিপরীতে পরীক্ষিত হয়েছিল। আমরা LSTM যোগ করেছি — একই প্যাডিং নিয়ম ও GRU-এর সমন্বিত সেটিংসসহ।

Regime	ট্রান্সফরমার	LSTM	পার্থক্য	p (পার্থক্য)	p (সমতা)	সিদ্ধান্ত
A মূল মানচিত্র	0.6540	0.6560	-0.0020	0.699	0.0029	সমান
B প্রশিক্ষিত আকার	0.6040	0.6085	-0.0045	0.450	0.0118	সমান
C অদেখা কাঠামো	0.6025	0.6115	-0.0090	0.150	0.0432	সমান
D অদেখা আকার	0.4865	0.4845	+0.0020	0.817	0.0304	সমান

LSTM-এর বিপরীতে চারটি শর্তেই সমতা প্রমাণিত — GRU-এর তুলনায়ও শক্তিশালী, যেখানে D regime শুধু সীমাবদ্ধ করা গিয়েছিল। আর LSTM তিনটির মধ্যে সবচেয়ে বড় মডেল:

মডেল	প্যারামিটার	আপেক্ষিক আকার	প্রশিক্ষণ সময়
Transformer-RoPE	156,310	1.00×	115 s
GRU	351,702	2.25×	51 s
LSTM	450,518	2.88×	54 s

ট্রান্সফরমার দুটি রিকারেন্ট মডেলের সমান ফল দেয় **GRU-এর ৪৪.৪% এবং LSTM-এর ৩৪.৭% প্যারামিটার দিয়ে**। তবে এটি প্রশিক্ষণে **২ গুণ ধীর** — এটিই সৎ লেনদেন।

৬.৫ আটটি পূর্ব-নিবন্ধিত পরিসংখ্যান পরীক্ষা

সব অনুমান পরীক্ষা চালানোর **আগেই** লিখে ভাঙ্গন কন্ট্রোলে জমা দেওয়া হয়েছিল (কমিট `1413afb`), যাতে পরে বদলানো না যায়।

পরীক্ষা	কী জানতে চায়	পার্থক্য	৯৫% CI	p (Holm)	ফল
H16-D	ট্রান্সফরমার > GRU, অদেখা আকার	+0.0045	[-0.012, +0.021]	1.000	না
H16-C	ট্রান্সফরমার > GRU, অদেখা কাঠামো	-0.0055	[-0.013, +0.002]	1.000	না
H17-B	ট্রান্সফরমার vs GRU, প্রশিক্ষিত আকার	-0.0060	[-0.016, +0.004]	1.000	না
H17-A	ট্রান্সফরমার vs GRU, মূল মানচিত্র	-0.0010	[-0.007, +0.005]	1.000	না
H18-D	ট্রান্সফরমার > প্রস্থ-মিলিত GRU	-0.0055	[-0.023, +0.012]	1.000	না
H18-B	একই, প্রশিক্ষিত আকার	-0.0015	[-0.018, +0.015]	1.000	না
H19-DT	এনটিটি অ্যাটেনশন ট্রান্সফরমারকে সাহায্য করে	-0.0055	[-0.024, +0.013]	1.000	না
H19-DG	এনটিটি অ্যাটেনশন GRU-কে সাহায্য করে	+0.0180	[-0.000, +0.036]	0.690	সবচেয়ে কাছাকাছি

৬.৬ পরীক্ষা v6 — একমাত্র আশাব্যঞ্জক ফলাফলকে যথাযথ দ্বিতীয় সুযোগ

H19-DG-ই একমাত্র পরীক্ষা যার আস্থার ব্যবধান প্রায় শূন্য ছাড়িয়ে গিয়েছিল। ১০টি সিডে আমরা শুধু খুব বড় প্রভাবই ধরতে পারতাম, তাই এটি **অপর্যাপ্ত ক্ষমতার, অপ্রমাণিত নয়**। আমরা প্রয়োজনীয় নমুনা সংখ্যা হিসাব করে **ঠিক ৩১টি সিডে একটি পুনরাবৃত্তি পূর্ব-নিবন্ধন** করেছি (কমিট 7261a4a), এবং **সম্পূর্ণ নতুন সিড** ব্যবহার করেছি যাতে এটি স্বাধীন হয়।

রান	n	EntityTransformer	DeepSets	পার্থক্য	প্রভাবের মাপ	p
v5 মূল	10	0.5000	0.4820	+0.0180	+0.61	—
v6 পুনরাবৃত্তি	31	0.4597	0.4652	-0.0055	-0.17	0.826
একত্রিত	41	0.4695	0.4693	+0.0002	+0.01	0.481

পুনরাবৃত্তির ফল এসেছে **বিপরীত দিকে**। ৪১টি সিড একত্র করলে পার্থক্য **+0.0002** — কার্যত ঠিক শূন্য। আগেই প্রতিশ্রুতি অনুযায়ী এই দাবি বাতিল করা হয়েছে এবং আর কোনো সিড যোগ করা হয়নি।

৭. কীভাবে জানলাম স্থাপত্যের দাবি ব্যর্থ — চারটি স্বাধীন উপায়

#	প্রমাণ	ফল
১	যাচাইকৃত পরিবেশে ৮টি পূর্ব-নিবন্ধিত পরীক্ষা, বহুবিধ-তুলনা সংশোধনসহ	সবগুলো অ-তাৎপর্যপূর্ণ
২	সেরা সম্ভাবনার যথাযথ-ক্ষমতার পুনরাবৃত্তি (একত্রিত n=41)	+0.0002
৩	সমতা পরীক্ষা — পার্থক্য একটি সীমার নিচে তা প্রমাণ	সমতা প্রমাণিত, p=0.0001
৪	প্রতিটি ছোট-নমুনার "জয়" যথাযথ নমুনায় পুনঃপরীক্ষা	চারটিই মিলিয়ে গেছে

চারবার আশাব্যঞ্জক ফলাফল যথাযথ পরীক্ষায় মিলিয়ে গেছে

আপাত আবিষ্কার	ছোট n-এ	যথাযথ n-এ
অদেখা আকারে ট্রান্সফরমার জেতে	+0.0333 (n=3)	+0.0045 (n=10)
প্রস্থ-নিয়ন্ত্রণ নিশ্চিত করে এটি স্থাপত্যগত	27.6% (n=3)	79.8% (n=10)
এনটিটি অ্যাটেনশন GRU-কে সাহায্য করে	d = 0.61 (n=10)	d = -0.17 (n=31)
চূড়ান্ত একত্রিত হিসাব	—	+0.0002 (n=41)

সিড-থেকে-সিড তারতম্য ($SD \approx 0.068$) ছোট নমুনা থেকে দাবি করা প্রতিটি প্রভাবের চেয়ে বড় ছিল। এটি নিজেই একটি প্রকাশযোগ্য আবিষ্কার।

৮. কেন ব্যর্থ হলো — পাঁচটি প্রকৃত কারণ

#	কারণ	প্রমাণ
১	ডেটাসেট খুবই ছোট। ৭টি অভিযান, কার্যকর নমুনা ৩.০৯। ট্রান্সফরমারের বড় ডেটা দরকার।	Kish n = 3.09
২	ক্রমগুলো ছোট। ১৮–২২ ধাপ, ১৬-টোকেন প্রেক্ষাপট। অ্যাটেনশনের সুবিধা আসে দূরবর্তী নির্ভরতা থেকে, যা এখানে নেই।	পর্বের দৈর্ঘ্য ১৮.৪
৩	ক্লাস্টারিং ক্রমের সমস্যাটিই সরিয়ে দিয়েছিল। নিজেদের উত্তর দিয়ে অভিযান ভাগ করায় এটি ৩-শ্রেণির শ্রেণিবিন্যাস হয়ে যায়।	ক্রম-মূল্য +0.0001
৪	হিসাব-পদ্ধতি ক্রম-গঠনের ৮৭% ফেলে দিয়েছিল।	4.83-এর মধ্যে 0.627 bits
৫	কাজটি প্রায় সম্পূর্ণ। দুই মডেলই ইতিমধ্যে নিখুঁত পূর্বাভাসের ৬২–৭৭% অর্জন করে, বাকি থাকে ~০.০২–০.০৩ — যা সিড-গোলমালের চেয়েও ছোট।	৫৬.৩ টেবিল

আপনার ডিফেন্সের জন্য গুরুত্বপূর্ণ সূক্ষ্মতা: ১, ২ ও ৫ নম্বর কারণ সমস্যাটির বৈশিষ্ট্য — ট্রান্সফরমারের ত্রুটি নয়। মডেলটি নষ্ট নয়। কাজটিতে কেবল যথেষ্ট ক্রমগত গঠন বা অবশিষ্ট সুযোগ নেই, যাতে অ্যাটেনশন নিজের শ্রেষ্ঠত্ব দেখাতে পারে।

৯. থিসিস যা দাবি করতে পারে — ইতিবাচক ফলাফল

দাবি ১ — ব্যবস্থাটি কাজ করে (এটিই মূল অবদান)

রক্ষী	আটকানোর হার	অর্থ
প্রতারণা নেই	0.3635	ভিত্তি
এলোমেলো টোপ	0.4935	টোপ সাহায্য করে
সেরা স্থির টোপ, আক্রমণকারীর মডেল নেই	0.5475	বুদ্ধিমান কিন্তু অন্ধ
TEMARL (শেখা আক্রমণকারী-মডেল)	0.6040 – 0.6175	+0.057 থেকে +0.070, $p \leq 0.0018$
নিখুঁত পূর্বাভাস (সর্বোচ্চ সীমা)	0.6390	উর্ধ্বসীমা

TEMARL নিখুঁত আক্রমণকারী-পূর্বাভাস ব্যবস্থার ৬২-৭৭% অর্জন করে। **আক্রমণকারীর উদ্দেশ্য মডেলিংয়ের মূল্য +0.148 থেকে +0.171** — এটি পুরো স্থাপত্যের ভিত্তিকেই বৈধতা দেয়।

দাবি ২ — ৪৪% প্যারামিটারে প্রমাণিত সমতা

এটি "পার্থক্য খুঁজে পাইনি" নয় — এটি পরিসংখ্যানগত প্রমাণ যে পার্থক্য একটি নির্ধারিত সীমার **চেয়ে ছোট** (TOST পরীক্ষা, ০.০২ সীমা)।

Regime	পার্থক্য	p (সমতা)	সিদ্ধান্ত
A মূল মানচিত্র	-0.0010	0.0001	সমান
B প্রশিক্ষিত আকার	-0.0060	0.0124	সমান
C অদেখা কাঠামো	-0.0055	0.0029	সমান
D অদেখা আকার	+0.0045	0.0527	০.০২০-এর নিচে সীমাবদ্ধ

LSTM-এর বিপরীতে ফলাফল আরও শক্তিশালী — **চারটি শর্তেই** সমতা প্রমাণিত ($p = 0.0029, 0.0118, 0.0432, 0.0304$)।

ট্রান্সফরমার ১৫৬,৩১০ vs GRU ৩৫১,৭০২ (৪৪.৪%) এবং vs LSTM ৪৫০,৫১৮ (৩৪.৭%)। প্রায় এক-তৃতীয়াংশ মডেলে সমান প্রতারণা-ক্ষমতা। খরচ: ২ গুণ প্রশিক্ষণ-সময়।

দাবি ৩ — পদ্ধতিগত আবিষ্কার (নিজেরাই প্রকাশযোগ্য)

- একটি পূর্ব-নিবন্ধিত পরিবেশ-গেট পাস করতে পারে, অথচ পরিবেশটি প্রকৃত অনুমানের জন্য অকেজো হতে পারে। আমাদেরটি তাই হয়েছিল: এটি জিজ্ঞেস করেছিল "আক্রমণকারীর তথ্যের কি কোনো মূল্য আছে?" (হ্যাঁ, ০.২৬৯৮) কিন্তু কখনো জিজ্ঞেস করেনি "শ্রেণি-নামের বাইরে ক্রম-তথ্যের কি মূল্য আছে?" (+০.০০০১)।
- স্থাপত্য তুলনার জন্য রেফারেন্স সিঁড়ি ও বৈধতা-গেট দরকার। এগুলো ছাড়া v4 এমন ৫টি মডেল থেকে ৮টি শূন্য ফলাফল দিয়েছিল যারা কখনো শেখেইনি।
- এই ক্ষেত্রে ছোট-নমুনার প্রভাব টেকে না। চারবারের চারবারই।

দাবি ৪ — ডেটা-সংক্রান্ত অবদান

- উৎস-যাচাইকৃত CAM-LDS ভিত্তি, যেখানে পাঁচটি পার্সার ত্রুটি খুঁজে সংশোধন করা হয়েছে, স্বাধীনভাবে লেখা দ্বিতীয় পার্সার দিয়ে যাচাইকৃত।
- একটি পরিমাপকৃত হিসাব-ত্রুটি: রূপান্তর সারণিতে একটি কলাম-ধ্রুবক, যা ডেটার ৮৭% ক্রম-তথ্য নষ্ট করেছিল।
- শব্দভাণ্ডার সম্প্রসারণ, যা "অজানা" হিসেবে ফেলে দেওয়া ৬.২০% আক্রমণ-পদক্ষেপ উদ্ধার করেছে।

১০. সং সীমাবদ্ধতা (পরীক্ষক ধরার আগেই বলুন)

- প্রশিক্ষণ হয়েছে **behaviour cloning** দিয়ে, **রিইনফোর্সমেন্ট লার্নিং** দিয়ে নয়। PPO-তে কোনো মডেলই কোনো বাজেটে স্মৃতিহীন বেসলাইন হারাতে পারেনি (২৪০ পর্ব → ০.৫১০, ১,২০০ → ০.৫২৩, বেসলাইন ০.৫৪৭৫)।
- PPO কেন ব্যর্থ হয় তা অমীমাংসিত**। দুটি অনুমান পরীক্ষা করে দুটোই ভুল প্রমাণিত: পুরস্কার/পরিমাপের দ্বন্দ্ব (সহস্রস্বক্ক +০.৯৮৩, তাই দ্বন্দ্ব নেই), এবং একটি লগ-সম্ভাবনা গড় করার ত্রুটি (ঠিক করায় ফল খারাপ হয়েছে)।
- নমুনা n=10** শুধু খুব বড় প্রভাব ধরতে পারে; যুক্তির ভার p-মান নয়, আস্থার ব্যবধান বহন করে।
- একটিমাত্র পরিবেশ, একটিমাত্র স্ক্রিপ্টেড আক্রমণকারী**। শেখে এমন আক্রমণকারী সব বদলে দিতে পারে।
- সংস্কারকৃত পরিবেশ ক্যালিব্রেটেড** — ২০টি প্রার্থীর মধ্য থেকে পূর্বঘোষিত শর্তে বাছাই; ভিন্ন ক্যালিব্রেশনে ফল ভিন্ন হতে পারে।
- LSTM-কে GRU-এর সমন্বিত সেটিংস দেওয়া হয়েছে**, নিজস্ব সার্চ নয়।

১১. সময়রেখা — প্রতিটি বড় সিদ্ধান্ত

পর্যায়	সিদ্ধান্ত	কেন	ফল
ডেটা	উৎস প্লেবুক থেকে CAM-LDS নতুন করে পার্স	হাতে তৈরি সংস্করণ অযাচাইকৃত	৬টি হারানো কৌশল (৬.২০%)
ডেটা	দ্বিতীয় স্বাধীন পার্সার লেখা	প্রথমটি যাচাই করতে	আরও ৩টি ত্রুটি, ৮টি পদক্ষেপ উদ্ধার
মডেল	রোটারি পজিশন এনকোডিং যোগ	সাইনুসয়ডাল ট্রান্সফরমারকে দুর্বল করছিল	+0.026 থেকে +0.070
মডেল	দুটির জন্যই সমান ১৬-ট্রায়াল টিউনিং	ন্যায্যতা	ব্যবধান 0.1388 → 0.0000
পদ্ধতি	রেফারেন্স সিঁড়ি তৈরি	সংখ্যাগুলো ব্যাখ্যাযোগ্য ছিল না	ক্রম-মূল্য = +0.0005 আবিষ্কার
পরিবেশ	রূপান্তর-সারণির ধ্রুবক সরানো	সংজ্ঞা অনুসারেই এটি শূন্য তথ্য বহন করত	ক্রম-মূল্য ১৬০ গুণ
পরিবেশ	ধরা-পড়ার নিয়ম পুনঃক্যালিব্রেশন	সংস্কার পরিমাপকে সম্পৃক্ত করেছিল	২০টির মধ্যে ১টি সব গেট পাস
পদ্ধতি	PPO → behaviour cloning	PPO-তে কোনো মডেল বেসলাইন হারায়নি (শুধু GRU দিয়ে সিদ্ধান্ত)	এরপর পাঁচটি মডেলই শিখেছে
পরিসংখ্যান	সমতা পরীক্ষা যোগ	"অ-তাৎপর্যপূর্ণ" ফলাফলকে কম বলছিল	সমতা প্রমাণিত, $p=0.0001$
পরিসংখ্যান	$n=31$ -এ ক্ষমতা-বিশ্লেষিত পুনরাবৃত্তি	সেরা সম্ভাবনা অপরিাপ্ত ক্ষমতার ছিল	পুনরাবৃত্তি হয়নি; বাতিল
মডেল	LSTM যোগ	তুলনা অসম্পূর্ণ ছিল	৯৬ দেখুন

১২. সততার রেকর্ড — পরীক্ষক যা যাচাই করবেন

কমিট	বিষয়বস্তু	সময়
7499d29	v4 পূর্ব-নিবন্ধন	v4 চালানোর আগে
1413afb	v5 পূর্ব-নিবন্ধন + পরিবেশ সংস্কার	v5 চালানোর আগে
0c25e12	v5 ফলাফল, ৮টি তুলনাই প্রকাশিত	পরে
7261a4a	সমতা পরীক্ষা + v6 পূর্ব-নিবন্ধন	v6 চালানোর আগে
4b53a26	v6 পুনরাবৃত্তির ফলাফল	পরে

একটি সংখ্যা যা কখনো উদ্ধৃত করা যাবে না

v5-এর ডেটা এক-পার্শ্বীয় (one-sided) পরীক্ষায় দিলে $p = 0.0431$ আসে, যা তাৎপর্যপূর্ণ দেখায়। **এটি বৈধ ফলাফল নয়।** v5 নিবন্ধিত হয়েছিল দ্বি-পার্শ্বীয়, বহুবিধ-সংশোধিত পরীক্ষা হিসেবে এবং তার মান $p = 0.690$ । ডেটা দেখার পরে পরীক্ষার ধরন বদলানো ঠিক সেই কারণেই যা একটি থিসিসকে বাতিল করে দেয়। ভুলবশত কেউ যেন উদ্ধৃত না করে, তাই এখানে লিখে রাখা হলো।

TEMARL · ব্র্যাক ইউনিভার্সিটি · অপূর্ব রায় (23101012), তুষিত রায় (23101350), মার্ক ডিপ্টো গোমেজ (23101537), ফারজানা আক্তার শুমি (23101059) · তত্ত্বাবধায়ক: মো. সাকির হোসেন · প্রতিবেদন তৈরি ৮ সেপ্টেম্বর ২০২৬। সব সংখ্যা রিপোর্জিটরির `results_v4/`, `results_v5/`, `results_v6/`, `results_v7/` থেকে যাচাইযোগ্য।